



작은 변경의 검증에서 컴파일러 업무의 개선으로

CPU 사례 · 전문가 판단 · 검토된 실행 절차
Compiler AX의 적용과 조건부 확장

Jihwan Ryu

류지환 · 지원자 작성 자료

2026년 7월 과제의 복기용 개정본

목차

코딩 에이전트의 초안을 실제 변경으로 채택하려면, 통과 기록만으로 설명되지 않는 판단을 확인해야 합니다. 개인 개발 환경과 공개 Rust SDK의 CPU 실험을 출발점으로, 담당 엔지니어의 판단을 작은 절차와 검사에 담고 다음 업무에서 검증하는 Compiler AX 적용안을 제시합니다.

I 직접 만든 환경과 확인한 결과

1. Agent-Assisted Development

03

개인 개발 환경은 어떤 문제를 해결하기 위해 만들어졌는가?

2. CPU Validation: Test Strengthening and Candidate Selection

04

실행 결과와 코드 검토는 각각 무엇을 확인했는가?

II 공개 스택에 맞춘 조직 적용

3. RNGD Architecture and the Compiler Stack

06

TCP-컴파일러·Runtime의 책임은 어디에서 나뉘는가?

4. Compiler AX: Expert Review and Bounded Delegation

07

무엇을 문서로 남기고, 무엇을 코드 검사로 강제할 것인가?

III 채택과 조건부 확장

5. Verification, CI Ratchets, and Change Review

09

검사·trajectory·PR을 어떤 판단에 연결할 것인가?

6. Adoption Scope and Technical Extensions

11

Compiler 업무와 탐색 정책은 어떤 근거가 있을 때 확장하는가?

References and Evidence Scope

12

직접 실행·공개 자료·미실행 제안의 원문과 경계

2026년 7월 제출 원본을 보존한 후속 개정본입니다. 1-2절은 개인 개발과 9월 16일 완료한 CPU 사례, 3절은 공개 스택, 4-6절은 조직 적용과 확장 제안입니다. 5.2절은 공개 Lab의 CI 구현도 구분해 설명합니다. 전문가 관찰·팀 도입·NPU 실행은 미실행입니다.

1. Agent-Assisted Development

추론 모델과 코딩 에이전트가 빠르게 발전할 때, 기존 백엔드·인프라 지식으로 어디까지 제품을 직접 만들고 제어할 수 있는지 확인하고 싶었습니다. Cursor와 Claude 계열 도구로 시작해 Codex 중심으로 작업하면서, 구현을 실행해 둔 동안 논문과 코드를 읽고 결과를 다시 검사하는 방식이 자리 잡았습니다. 혼자 다룰 수 있는 범위가 넓어진 만큼 **무엇을 바꿨고 어떤 근거로 받아들였는지**를 남기는 일이 중요해졌습니다.

한 파일을 고친 뒤 같은 오류가 여러 경로에서 반복되면 파일별 수정 요청을 늘리기보다 원인을 다시 나눴습니다. 공통 의존성 설정의 문제인지, 도구의 성공 응답을 작업 완료로 잘못 읽었는지, 검사한 코드와 지금 코드가 같은 버전인지부터 확인했습니다. 관점을 바꾼 결과는 재현 입력·허용 변경·검사 명령으로 구체화했습니다. 문제를 더 추상적으로 말하는 데서 끝내지 않고, **어디에 개입하면 가설을 구별할 수 있는지**까지 내려오는 방식입니다.

1.1 Development Workflow and Evidence

작업은 요구와 관련 코드를 읽고 이미 구현된 부분을 제외하는 데서 시작합니다. Codex에는 남은 문제와 변경 범위를 주고, 독립적인 조사·구현은 나누되 같은 파일의 동시 수정은 피합니다. 초안 뒤에는 diff를 처음 요구와 대조하고 단위 검사·E2E·실제 화면을 필요한 범위에서 확인합니다. 검사 결과가 좋더라도 사용 예시나 문서가 다른 revision을 가리키면 완료로 두지 않습니다. GEODE의 개발 규약과 작은 회귀 검사는 이 과정을 다음 작업에서도 사용할 수 있게 만든 장치입니다.[1]

주 개발 도구는 Codex이며, GEODE와 Eco²는 이 방식으로 개발한 시스템입니다. 다음에 설명할 SIL·Crucible은 GEODE의 행동과 작업 절차를 시험하는 실험 구성입니다. 개발을 수행하는 도구, 개발 대상, 그 대상을 평가하는 구성을 구분해 설명합니다.

1.2 Runtime and Recovery: GEODE and Eco²

장기 도구 작업을 수행하는 런타임 **GEODE**에서는 모델의 다음 행동 제안과 실제 실행 권한을 나눴습니다. ReAct 기반 실행에 tool·state·구조화된 hook을 두고, 계획은 관측에 따라 수정하도록 했습니다. 필요한 skill과 작업 정보를 선택해 문맥을 조립하며, 호출마다 허용 범위·예산·승인 조건을 확인합니다. 검증과 제한된 재시도는 작업에 맞게 사용합니다. 같은 도구·입력·결과가 반복되도 성공 응답만 이어지는 고장을 만났을 때에는, 반복 조건을 종료 판단에 추가하고 실행 루프의 mock 회귀 검사로 확인했습니다.[1]

분리배출 안내 서비스 **Eco²**에서는 AI 처리의 수명이 HTTP 연결보다 길었습니다. 작업 식별자, 비동기 실행, 순서가 있는 이벤트 이력, 실시간 전달을 분리해 연결 종료와 실제 작업 완료를 구별했습니다. 복구 경로에서는 전달에 실패한 이벤트까지 ACK해 재회수 대상에서 빠지는 문제를 찾았습니다. Consumer와 Reclaimer가 성공한 처리만 ACK하도록 수정하고 같은 성공·실패·예외 조건으로 전후 동작을 대조했습니다. 이 검사는 이벤트 전달 복구를 다뤘으며 AI 작업을 재실행한 실험과는 다릅니다.[2]

두 사례에서 공통으로 바뀐 것은 성공을 읽는 방법이었습니다. 도구가 응답했는지와 목표가 진전됐는지, 전달을 시도했는지와 완료했는지를 나눠야 다음 행동을 정할 수 있었습니다. 이 경험은 Compiler AX Lab에서 **테스트가 통과했는지와 테스트가 오류를 구별할 수 있는지**를 따로 확인하는 질문으로 이어졌습니다.

1.3 Simulation and Workflow Evaluation

GEODE의 **SIL**은 세 부분으로 구성했습니다. Seed Scenario Generation에서는 시험할 행동을 정하고 후보 시나리오를 생성·비평·pilot으로 좁혔습니다. Simulation에서는 Petri의 auditor·target·judge 상호작용을 사용해 반복 탐색이나 오래된 문맥 유지와 같은 행동을 관찰했습니다. autoresearch 방식의 실험에서는 지침 한 항목을 바꾸고 재평가 결과에 따라 유지하거나 복원하도록 했습니다. 기각 후에도 설정이 남던 문제를 수정하면서 판정 기록뿐 아니라 실제 복원 상태를 검사했습니다.[3]

Crucible은 후보 탐색과 최종 채택의 비교 조건을 분리하는 구성입니다. 개발 중 관찰한 결과로 다음 후보를 고를 수 있지만, 최종 확인의 입력과 판정 기준까지 후보가 바뀌게 하지는 않습니다. 일부 시나리오는 모의 도구 응답을 사용하고 재평가 실행은 선택 사항이므로, 이 구조를 모든 후보가 자동 검증·배포된 이력으로 읽을 수는 없습니다.



그림 1. 성공 응답·전달 시도·기각 기록이 실제 완료를 뜻하지 않았던 세 사례입니다. 각 차이를 종료·ACK·설정 복원 조건과 해당 검사로 바꿨습니다. 서로 다른 프로젝트의 독립된 사례입니다.

비교 환경도 검사 대상이었습니다. GEODE와 native Codex의 Terminal-Bench 2.1 비교에서는 매번 작성하던 샌드박스·스크립트 대신 Harbor로 과제·검증기·산출물 수집을 맞췄습니다. 89개 과제에 양쪽 각 5회, 총 890셀을 계획했지만, 9월 12일 분석에는 검증기 호환성 처리 뒤에도 인프라 무효가 남았습니다. 전체 비교는 측정 불성립으로 정리했습니다. 외부 하네스를 채택해도 환경의 실패를 에이전트 실패와 구분하는 책임은 남습니다.[4]

2. CPU Validation: Test Strengthening and Candidate Selection


공개 `furiosa-opt` 의 double-buffering 실행만으로 그룹별 출력이 올바른지는 알 수 없었습니다. 첫 과제는 제품 커널 최적화가 아니라 테스트의 판정 능력 보강으로 좁혔습니다. 독립 scalar reference와 좌표별 비교를 추가하고, 정상 구현은 통과하면서 의도한 오류는 수치 assertion에서 잡는지 확인했습니다. 후보가 제품 코드나 보호된 평가 기준을 바꾸는 것은 허용하지 않았습니다.[5]

2.1 A/B Controls and Code Review

A에는 상세 공통 요구를, B에는 같은 요구와 조사·진단·수정·검증 절차를 제공했습니다. 공개 코드와 도구는 같았고 초안 뒤 수정은 한 번으로 제한했습니다. 두 코드와 설명을 모두 고정한 뒤 보호된 정상·오류 구현을 검사했으며 그 결과를 다시 후보 수정에 주지 않았습니다. 한 과제의 한 쌍이므로 절차 효과의 일반화보다 실행 가능성과 검토할 차이를 확인하는 파일럿입니다.

최종 8개 판정 단위에서 각 후보는 정상 구현 3개를 통과시키고 자격이 확인된 오류 1개를 검출했습니다. 의도한 실패는 컴파일 오류나 timeout이 아니라 지정 수치 assertion에 도달했습니다. 이 작은 대조군에서 관측된 오탐·미탐은 0이지만, 확인하지 않은 오류까지 없다는 뜻은 아닙니다. 판정 단위는 고정 후보×구현이며, 서로 다른 8개 과제를 수행한 결과가 아닙니다.[5]

실행 완료 → 별도 코드 검토 → 사용자 선택



사용자 Rust 전문성·Furiosa 승인·NPU 검증을 뜻하지 않습니다.

붉은 테두리: 사용자 선택

그림 2. 같은 검사를 통과한 사실과 특정 코드를 채택한 이유는 다릅니다. 후속 소스 검사는 선택 근거이며 A/B의 추가 실행 표본이 아닙니다.

후속 검토에서는 입력이 서로 다른 출력 위치를 구별하는지 물었습니다. A의 여섯 입력에서 각 좌표의 기대값을 순서대로 묶으면, 2,560개 좌표 중 서로 다른 묶음은 2,332개였습니다. 서로 다른 두 좌표가 같은 묶음을 갖는 경우, 그 두 위치를 항상 교환하는 오류는 해당 입력만으로 구별할 수 없습니다. 정상값을 더 많이 계산했다는 사실과 위치를 더 잘 식별한다는 성질은 달랐습니다.

B는 출력의 일렬 번호를 251로 나눈 나머지와 묶에 각각 1을 더한 값을 두 입력의 기대값으로 사용했습니다. 두 값을 함께 읽으면 2,560개 좌표가 모두 구별됩니다. **같은 위치 교환이 두 입력에 적용되는 오류**를 드러낼 수 있고, 입력·기대값이 bf16으로 정확하게 표현되는 정수 범위를 벗어나면 중단하는 검사도 명시했습니다. 반면 A는 기저 입력으로 reduction 축을 더 넓게 탐침하고 실패 메시지가 자세합니다. B의 기저 탐침은 좁으며 dense 입력으로 전체 축을 확인하므로, 모든 결함에 우월한 후보로 순위를 매기지는 않았습니다.

9월 16일 작성자는 Codex의 보조 검토를 바탕으로 **B를 고정 크기 CPU 테스트 보강안으로 채택**했습니다. A는 오답이 아니라 미선택 후보로 보존했습니다. 같은 Device로 연속 호출해도 실제 HBM 할당 재사용은 보장되지 않으므로 물리 버퍼 재사용·DMA 중첩의 검증으로 확대하지 않았습니다. 이 결정은 Furiosa 담당자의 전문 검토나 upstream 채택과도 별개입니다.[5]

완료한 것은 작은 테스트 변경과 근거를 갖춘 코드 선택입니다. 두 후보의 대조 결과는 같았으며 추가 절차의 효과는 확인하지 못했습니다. 생성 순서가 B 다음 A로 고정됐고 계정·캐시 조건도 변했으며 사람의 총 작업시간은 측정하지 않았습니다. 후속 소스 검사는 B의 제한된 채택 근거이지 절차의 생산성 우위를 입증하는 추가 표본이 아닙니다.

2.2 Validation Scope and Limitations

별도 mapping parser 사례에서는 두 진입점에서 문법→AST→오류 문구·byte 위치를 확인하도록 검사를 6개에서 12개로 늘렸습니다.

소스를 다시 꺼내 원본·보강본·공개 오류 사본의 빌드 디렉터리를 분리한 재현에서도 정상 검사는 통과하고 오류 사본은 지정 assertion에서 실패했습니다. 의존성과 toolchain은 재사용했으므로 완전히 새 환경의 재현과는 구분합니다. 앞선 환경 권한 실패는 테스트 전에 멈춘 무효 실행으로 보존했습니다.

B와 별도로, 앞서 공개한 double-buffering 테스트와 parser 변경을 함께 적용한 CPU 통합 검사도 완료했습니다. 통합 검사·native x86 smoke·합성 상태 복원은 각각 다른 실행이며 A/B 분모에 더하지 않았습니다. 상세 검사 수와 실행 환경은 후주 5에 둡니다.[5]

남은 질문은 담당자의 실제 판단을 절차에 담았을 때, 다른 과제에서 필요한 검사를 빠뜨리지 않고 검토·재작업 부담을 줄일 수 있는 가입니다. 다음 절부터는 공개 스택의 책임을 나눈 뒤 이를 조직에서 확인할 적용안을 제시합니다.

3. RNGD Architecture and the Compiler Stack

RNGD에서는 같은 계산도 **데이터를 어디에 남기고 언제 옮기는지**에 따라 비용이 달라집니다. TCP(Tensor Contraction Processor)는 다양한 텐서 모양의 병렬성과 재사용을 활용하도록 설계했습니다. Compiler는 이 유연성을 텐서 배치와 실행 순서로 구체화합니다. 자동 생성량보다 먼저 살필 것은 현재 표현과 관측으로 어떤 선택을 구별할 수 있는지입니다.[6]

물리 데이터 흐름. HBM과 PE의 SRAM 사이에서는 Tensor DMA가 데이터를 옮깁니다. SRAM의 값은 fetch 경로를 거쳐 수축·벡터·전치 연산기에 전달되고, 결과는 commit 경로로 SRAM에 기록됩니다. 값을 재사용하면 HBM 왕복을 줄일 수 있지만, 공간을 오래 점유하면 다른 작업의 배치가 제한됩니다. 출력 layout도 다음 연산의 입력 변환 비용에 영향을 줍니다. 선택들은 독립적인 스위치가 아니라 메모리·의존성·실행 순서로 연결돼 있습니다.




그림 3. 계산 표현·컴파일 산출물·장치 실행을 구분해야 같은 자연 현상에서도 수정할 계층을 찾을 수 있습니다. 공개 자료 재구성이며 3세대는 개발 계획입니다.[6-8]

3.1 Programming Model and Semantic Constraints

공식 발표의 **PyTorch → TCL → TCP Virtual ISA → TCP Physical ISA**는 계산 의도를 점차 실행 가능한 형태로 바꾸는 계층입니다. TCL은 tensor contraction의 의미를 남기고 compiler가 tiling·fusion·mapping·scheduling을 선택하도록 합니다. 공개 Rust `furiosa-opt`는 관찰 가능한 커널 작성·검사 경로지만, 공개 driver는 설치 안내 stub이므로 production compiler의 내부 pass 구현까지 이 저장소에서 수정할 수 있다고 전제하지 않습니다.[7]

변환의 기준은 명령 형태의 동일성이 아니라 요구된 값·효과·순서입니다. Buffer를 재사용하려면 이전 값을 읽는 소비가 끝난 뒤 덮어써야 합니다. 직렬 host 실행에서 값이 맞아도 장치에서 동시에 실행할 때의 수명과 순서가 맞는지 별도 확인이 필요합니다. 변경이 테스트 보강인지, 의미를 보존하는 최적화인지, 잘못된 동작을 바꾸는 bug fix인지 먼저 정해야 기준도 맞게 세울 수 있습니다.[9]

Compiler가 만든 executable은 Runtime이 읽어 프로그램과 메모리를 관리하며 실행합니다. Driver·firmware·PE Runtime은 장치 실행을 받치고, Furiosa-LLM은 모델과 요청을 제공합니다. FXB의 fingerprint·compiler revision 일치는 산출물 호환성 확인입니다. 요청의 품질·지연·처리량은 실제 workload에서 다시 봐야 합니다. x86-64 요구도 배포 host toolchain의 조건이지 NPU의 텐서 명령 집합을 뜻하지 않습니다.[8]

3.2 Model Integration and Serving Operations

Solar의 Daum 적용은 모델 그래프와 최적화 경로를, EXAONE 협업은 모델·정밀도·컴파일 산출물과 서빙 설정의 관계를 살필 이 유를 제공합니다. Bucket 구성을 바꾼다면 모델·compiler 버전·나머지 설정·측정 workload를 고정하고 후보별 FXB를 다시 만들어 비교합니다. 별도 KV runtime 설정의 효과는 같은 FXB와 입력·출력 길이·동시성에서 확인합니다. 공급사가 발표한 집계 성능만으로 각 변경의 기여율을 계산할 수는 없습니다.[10]

삼성SDS NPUaaS와 Backend.AI 공동 백서는 장치 자원 배정·세션 수명·서빙 운영을 함께 보여 줍니다. 대기 시간이 장치 배정에서 생겼다면 compiler patch보다 자원 관리가 먼저일 수 있습니다. SDK의 host 준비와 NPU 실행 겹치기도 커널 계산 단축과 다른 개입입니다. 실제 업무에서는 담당자와 지연·실패가 발생한 층을 확인한 뒤 수정 범위를 정하겠습니다.[11]

Compiler AX 공고의 범위도 커널 생성에 한정되지 않습니다. 개발·리뷰·디버깅·CI/testing·문서와 도구 정착을 실제 팀 업무에서 개선하는 역할입니다. 공개 스택은 첫 질문을 정하는 근거이며, 작업의 빈도·재작업·검토 부담은 담당자의 실제 기록으로 확인해야 합니다. 이 순서를 지켜야 작은 유지보수의 개선도 직무 기여로 완결할 수 있습니다.[12]

4. Compiler AX: Expert Review and Bounded Delegation

개인 프로젝트의 B 선택을 전문 조직으로 옮길 때 부족한 것은 더 큰 에이전트 엔진보다 **어떤 조건을 보존하고 언제 판단을 멈추는 지에 대한 담당자의 근거**입니다. 첫 적용에서는 실제 엔지니어의 한 작업을 함께 따라가겠습니다. 기존 patch 검토, 새 parser 경계 사례, 반복되는 테스트 준비, 문서 예제 불일치 가운데 실제 지연과 재작업이 관찰되는 일을 고릅니다. 현재 완료한 parser 사례를 새 독립 과제로 다시 세지는 않습니다.

4.1 Expert Observation and Procedure Design

담당 엔지니어가 열어 본 코드·진단, 선택한 검사, 버린 가설, 판단을 보류한 조건을 기록합니다. 가능하면 에이전트의 제안을 보기 전 판단을 먼저 남겨 도구가 검토자의 생각을 유도하는 영향을 구분합니다. Compiler 담당자는 의미·호환성·reference·허용 오차와 채택을 소유하고, AX 엔지니어는 반복 절차·도구 연결·사용 비용을 다룹니다. 한 사례의 취향을 모든 업무의 필수 규칙으로 만들지 않습니다.

기록 전체를 지침에 넣으면 다음 작업에 필요한 조건이 묻힙니다. MD에는 **적용할 문제, 필요한 입력과 revision, 수행 순서, 기대 관측, 적용하지 않을 조건, 중단 후 문의할 담당자**만 남깁니다. 결과가 기계적으로 판별되는 조건은 기존 script나 test에 넣고, 명세 해석이 필요한 부분은 검토 항목으로 둡니다. 담당 엔지니어가 MD와 검사의 적용 범위를 검토·승인한 뒤, 그 범위의 재현·증거 수집

·국소 수정만 에이전트에 맡깁니다. MD는 실행 선택을 안내하고 검사는 실제 결과를 판정하도록 역할을 나눕니다.




그림 4. 전문가의 판단을 기록한 뒤, 다음 작업에서 올바르게 사용되는지 확인하고 위임 범위를 정합니다. 현재 CPU 사례와 구분되는 미실행 조직 적용안입니다.

예를 들어 진단 테스트의 오류 위치를 보강한다면, 문법 입력만 더 생성하게 하지 않습니다. 담당자가 위치 단위와 기대 AST를 정한 뒤 에이전트가 누락된 경계 입력을 제안하고 두 parser 진입점의 결과를 대조하게 합니다. 기대 메시지를 구현 출력에서 그대로 복사하면 같은 오류를 reference에 심을 수 있으므로, 원래 문법 계약과 독립 예제로 확인합니다. 명세가 불명확한 입력은 성공·실패 중 하나로 억지 분류하지 않고 담당자에게 돌립니다.

4.2 Task Planning and Patch Review

새 문제라면 먼저 가설을 나눕니다. 같은 실패가 입력 범위 누락 때문인지, 공통 설정 때문인지, 잘못된 실행 결과를 읽었기 때문인지에 따라 필요한 수정이 달라집니다. 서로 다른 원인을 겨냥한 후보만 별도 작업공간에서 병렬로 만들고, 기존 patch가 이미 있다면 재생성하지 않고 재현·검토·보완부터 시작합니다. 가설을 구별할 실행부터 골라 검토 대상을 좁히되, 그 준비 비용까지 포함한 효과는 다음 과제에서 확인하겠습니다.

시나리오 생성자는 빠진 입력과 실패 조건을 제안하고, **실제 build/test는 담당자가 정한 reference에 따라 결과를 판정**합니다. SIL에서 사용한 모의 상호작용 도구는 이 실행 검사를 대신하지 않습니다. 후보를 만들고 비교하는 연구 사례에서도 이 역할 분리를 참고했습니다.[13]

기본 경로는 baseline 재현→허용된 국소 변경→변경 대상 검사→회귀 검사→리뷰입니다. 실패하면 에이전트는 오류 위치·기대값과 실제값·현재 diff로 원인을 다시 좁힙니다. 환경 실패에는 코드 수정을 요청하지 않고 환경을 복구하며, 기준 자체가 잘못됐다면 후보 작업을 멈추고 평가 기준을 별도 변경으로 검토합니다. 같은 오류·가설·코드가 반복되거나 예산이 끝나면 미해결 조건을 남기고 종료합니다.

4.3 Procedure Reuse and Adoption Criteria

첫 절차가 생긴 것과 재사용에 성공한 것은 다릅니다. 새 과제에서는 기존 작업 방식과 변경할 절차의 revision을 먼저 고정하고, 실제로 읽힌 MD 조항과 적용 제외 조건을 기록합니다. 비교에는 같은 task 유형·공통 요구·모델·도구·검사 기준·예산을 사용하고 생성 순서와 환경 차이를 남깁니다. 시작 전에 업무에 맞는 이익 지표 하나와 필수 정확성·검사 누락 방지 조건을 정합니다. 유지·적용 범위 축소·폐기·판정 보류의 조건도 결과를 보기 전에 담당자와 합의합니다.

시간은 준비·생성·실행 대기·사람 검토·재작업으로 나눠 기록합니다. 병렬 생성 뒤 통합 대기과 중복 수정이 늘면 전체 완료는 늦어질 수 있습니다. 반대로 실제 결함을 더 찾아 검토 시간이 늘었다면 시간만으로 절차를 폐기하지 않습니다. 사전에 정한 이익과 안전 조건으로 판단하고, 표본이나 비교 조건이 부족하면 효과 판정을 보류합니다. 올바르게 사용된 사례와 개선 효과가 확인된 사례를 구분하겠습니다.

5. Verification, CI Ratchets, and Change Review

Compiler 개발에서 통과한 관측은 판단의 시작이기도 합니다. 현재 소스의 바이너리인지, 필요한 테스트가 실제 실행됐는지, 정상 구현을 잘못 거절하지는 않는지 확인해야 결과를 사용할 수 있습니다. 이번 CPU 사례도 값 검사 뒤에 입력 식별성을 다시 검토했습니다. 팀 적용에서도 검사기 자체의 판정 능력과 실행 환경의 유효성을 분리하겠습니다.

5.1 Failure Classification and Test Validity

아래 4분면은 빌드·실행이 성립한 CPU 수치 검사에만 적용합니다. 양성은 지정 수치 assertion이 실패해 검사가 결함을 보고한 경우입니다. 실제 정상·결함 여부와 나눠 분류하며, 기대 동작과 실행 단계가 다르면 다른 판정이 필요합니다.

적용 대상	현재 보유한 근거	판정 위치
CPU 수치 검사	고정 A/B 각 정상 3건·결함 1건	아래 4분면. 단위는 후보×구현
컴파일 거절이 기대 동작인 검사	별도 통합 실행의 compile_fail doctest 44개	기대한 거절이면 해당 doctest 통과. A/B에 합산하지 않음
후보 코드의 빌드 오류	수정 전 B 초안의 E0599	빌드 FAIL·후속 수치 검사 NOT_RUN. 최종 집계 제외
준비·실행 불성립	별도 parser 재현의 초기 준비 실패	무효 실행으로 보존. 수치 검출로 세지 않음
정적 schedule·NPU·서빙 성능	이번 파일럿에서 미측정	별도 실행·판정 필요. CPU 결과로 대체하지 않음

다음은 §2의 고정 A/B 결과를 로그·소스 대조와 Codex 보조 검토로 분류한 값입니다. 새 실행이나 Furiosa 전문가의 승인이 아닙니다. 대조군의 자격은 사전에 정한 검사 계약으로 확인했습니다.[5]

검사가 내린 결과	정상 대조군	자격이 확인된 결함 대조군
통과	TN: A 3 · B 3 정상 구현 통과	FN: A 0 · B 0 결함 미검출 시 입력·reference·assertion 점검
지정 수치 assertion에서 실패	FP: A 0 · B 0 정상 구현 거절 시 기준·허용 범위 점검	TP: A 1 · B 1 의도한 결함 검출

8개 단위의 관측이며 일반적인 검출률 추정이 아닙니다. 예상 밖 빌드 실패, timeout, 0개 실행, 무관한 panic은 수치 검출로 세지 않습니다. 후보의 빌드 회귀와 환경 실패를 별도 진단하고, 실행되지 않은 후속 검사는 NOT_RUN으로 남깁니다.

성능 후보 선택은 또 다른 판단입니다. 정적 비용이 나빠 보인다는 이유로 실제 개선 후보를 너무 일찍 버릴 수 있으므로, 필요하면 승인된 예산 안에서 일부 대조 후보를 장치에서 확인합니다. 값의 정확성과 속도를 하나의 집계값으로 합쳐 오류를 상쇄하지 않습니다.[14]

5.2 Regression Tests and CI Ratchets

수정한 결함을 다음 변경에서도 검출하려면 재현 입력과 기대 동작을 회귀 검사로 남겨야 합니다. 조직 적용에서는 결함이 있는 판본에서 실패하고 수정본에서 통과하는 최소 검사를 만든 뒤, 담당자가 명세와 적용 범위를 확인하도록 하겠습니다. 승인한 검사는 관련 경로의 후속 PR에서 필수로 실행합니다. **CI ratchet은 검토한 회귀 검사를 후속 변경의 필수 조건으로 유지해 같은 결함을 다시 검출하는 절차입니다.** 기존 자체에 결함이 있으면 근거와 대체 검사를 별도 검토하며, 후보가 테스트 삭제나 허용 오차 완화로 통과하게 하지는 않습니다.

검사기나 reference를 고치면 영향을 받은 이전 결과를 식별합니다. 과거 기록은 보존하되, 바뀐 공통 기준으로 다시 검사하기 전에는 이전 PASS를 새 비교·채택의 근거에서 제외합니다.

공개 Compiler AX Lab에는 이 절차를 받치는 고정 검사와 CI 게이트를 구현했습니다. Python 검사는 최소 16개 실행과 skip 없음을 요구하고, 변경 경로로 선택된 필수 job이 실패·취소·누락되거나 예상과 달리 건너뛰어지면 최종 lab-ci 가 실패합니다. Rust CI는 독립 reference의 검사와 고정 소스에 대한 patch 적용 가능성까지 다루며, SDK 통합·NPU 실행은 별도입니다. 새 실패의 테스트 편입은 검토된 변경으로 수행하며 자동 생성·등록 기능은 두지 않았습니다.[5]

코드 변경에는 기존 Rustfmt·Clippy·단위·통합 검사와 해당 API·문서 확인을 연결합니다. 독립 reference도 입력 범위·정밀도·인덱스 계산을 검토해야 합니다. Static compile, CPU 값, schedule, 실제 장치 측정은 서로 다른 성질을 확인하므로 작업이 겨냥한 위험에 맞게 선택합니다.[7]

5.3 Trajectory and Artifact Provenance

필요한 기록은 에이전트의 장황한 사고 설명이 아니라 **요청·기준 revision→관측과 가설→명령·도구 결과→diff와 산출물→검토 결정**입니다. Codex의 도구 호출·결과와 Git diff, 기존 검사 로그를 사용하고 작업·turn·call 식별자로 연결합니다. 원문은 보존하되 검토용 요약은 현재 revision·핵심 실패·미해결 조건·원문 위치를 우선 제공합니다. 중단된 명령은 남은 프로세스·파일·자원까지 확인한 뒤 재시도합니다.

해시는 파일의 동일성을 확인하지만 실행 조건과 결과의 의미까지 설명하지는 않습니다. 전체 로그를 큰 요약이나 객체 하나로 묶으면 필요한 구간을 찾는 비용도 커집니다. 검토자가 요약에서 원문으로 이동할 수 있도록 실행별 manifest에 생산 명령·revision·원문 위치·완전성·hash를 함께 남기겠습니다. 원문은 단계별로 나눠 조회하되 결합할 때 같은 작업의 기록인지 확인합니다. 기존 파일과 색인으로 충분한 동안 새 데이터베이스는 도입하지 않습니다.[15]

재현의 완료도 hash 일치로 끝나지 않습니다. 같은 명령과 조건에서 의미 있는 검사가 실제 실행됐는지, 결과가 필요한 산출물에 연결됐는지 확인합니다. 누락된 call/result, 잘린 출력, 불명확한 종료기 있으면 확인된 범위와 빠진 범위를 나눕니다. 원문 보존 범위는 접근 권한과 보존 기간으로 관리하며, 보호된 평가나 계정 정보는 공개 PR에 실지 않습니다.

5.4 PR Integration and Merge Approval

Dioxus의 운영 회고는 코드를 많이 만든 것과 동료가 쓸 제품을 마친 것을 구분합니다. 여기서는 도구의 결과를 실제 환경에서 확인하고 API·문서·예제까지 맞추는 운영 원칙으로 적용합니다. 공개 AGENTS와 task별 architecture 문서처럼 진입 지침은 짧게 두고, 변경할 경로의 규칙과 실제 코드는 작업에 맞게 읽습니다. 외부 조직의 규칙을 내부 관행으로 일반화하지 않습니다.[16]

PR에는 문제와 재현 조건, 선택한 수정과 버린 대안, 보존할 동작, 실행한 검사 수와 결과, 남은 판단을 담습니다. LLM은 설명과 누락을 점검할 수 있지만 실패한 코드 검사를 뒤집지 못합니다. 담당자는 의미·호환성·영향 범위를 검토하고, base나 head가 바뀌면 현재 조합을 다시 검사합니다. 저장소 병합은 합의된 Git 흐름을 따르며, target 실행 승인과 배포는 별도 결정으로 남깁니다.

한 작업의 완료는 재현한 문제에 대응하는 diff, 필요한 검사, 담당자의 검토, 동료가 실행할 예제·문서가 같은 revision에서 맞는 상태입니다. 실제 팀에서는 동료가 이를 다시 사용하는 비용까지 확인하겠습니다. AX의 기여는 생성량이 아니라 이 조건을 만족하는 변경을 적은 재작업으로 전달하는 데 있습니다.




그림 5. 검토한 변경과 CI가 검사한 revision을 맞춘 뒤 병합합니다. 문서·예제·복구 경로까지 확인하되, 병합과 배포 승인은 구분합니다. 조직 적용 제한입니다.

6. Adoption Scope and Technical Extensions

다음 적용에서는 **자동화 권한과 기술 범위를 나눠, 한 번에 한 조건씩 바꾸겠습니다**. 실제 담당자의 업무에서 검토한 절차가 유용한 지 확인한 뒤, 반복 사용이 필요한 인접 업무와 추가 검사가 필요한 기술 영역을 구분합니다.

6.1 Host, Compiler, and Device Validation

저장소 업무부터 반복 사용을 확인합니다. 실제 담당자가 선택한 새 유지보수 과제에서 재현·국소 수정·리뷰·문서 중 한 범위를 맡습니다. 검토된 MD가 올바르게 사용되고 필요한 검사·문기가 유지됐는지 확인한 뒤, §4.3에서 미리 정한 기준에 따라 인접 작업으로 넓히거나 적용을 제한합니다. 사용 기록만 있고 효과가 불분명하면 확장을 보류합니다. 온보딩과 Q&A에서는 동료가 적용 경계와 중단 조건을 이해했는지 확인하겠습니다.[12]

컴파일과 schedule은 다른 위험을 확인할 필요가 있을 때 연결합니다. 호환 도구와 compiler binary를 확보하고, 담당자가 변경 가능한 mapping·순서·자원 선택을 정하면 동일 조건의 baseline과 candidate를 비교합니다. Schedule에서 대기 구간을 발견했다면 의존성 때문인지 공유 자원 때문인지 구분한 뒤 한 선택을 바꿉니다. 정적 계획이 좋아진 후보는 실제 장치에서 확인할 대상으로 남습니다. 내부 lowering을 수정하는 일은 실제 소스·명세·검사기 접근이 확보된 별도 과제입니다.[17]

물리 RNGD와 모델 서빙은 접근 조건을 갖춘 별도 실행입니다. 장치·driver·firmware·runtime과 workload를 고정하고 값·의존성·반복 timing을 확인합니다. 모델 업무에서는 FXB 호환성 뒤에 출력 품질을, 서비스 업무에서는 같은 입력/출력 길이·동시성·cache 조건에서 TTFT·TPOT·실패·처리량을 확인합니다. 기존 FXB의 서빙 검증은 자체 커널 변경 없이 시작할 수도 있습니다. 일반 CPU VM이나 Token Factory 크레딧은 RNGD 접근을 대신하지 못합니다.[8]

기술 범위는 작업·자원에 따라 선택하고, 위임 권한은 별도로 승인합니다

현재 확인 · CPU 범위

CPU 검사 · B 채택

고정 크기 CPU 테스트
A/B 대조군 결과는 동물

결정: 사용자

근거: 실행·코드 검토

다음 공통 준비 · 참여와 접근 승인 후 시행할 제안

전문가 업무 관찰

Agent 제안 전에 기록
선택 이유 · 조건 · 예외

담당: Compiler 담당자

근거: 실제 작업·판단

검토된 MD 절차

AX 작성 · 담당자 검토
적용·중단 조건을 명시

담당: AX + 도메인

근거: 승인한 revision

새 작업에서 사용

읽은 절차·행동을 연결
정확성·검토 비용 확인

담당: AX + 작업 소유자

근거: 실행·수정 기록

다음 경로는 순위가 아닙니다

필요한 범위만 선택합니다

조건이 없으면 보류합니다

없는 도구·장치를 가정하지 않음

작업 · 도구 · 장치?

AX + 담당자 선택

저장소·검사 접근

배포 도구·target 확인

장치·모델·부하 확보

Host 개발·유지보수

리뷰 · 문서 · 테스트 · CI

담당: AX + 코드 소유자

근거: diff·검사·검토 비용

도구 재사용·재작업까지 확인

정적 컴파일·schedule

도구·target 호환 확인 후

담당: Compiler 엔지니어

근거: 산출물·정적 자원 제약

실측 처리량과 구분

실제 RNGD·모델 서빙

장치·워크로드 승인 후

담당: Compiler·서빙 담당자

근거: 출력·지연·처리량

모델·부하·소프트웨어 고정

공통 승인 경계

AX는 절차·도구·효과 측정, 도메인 담당자는 평가 기준·채택·확대를 소유합니다.

후보 Agent는 승인 범위만 실행하며 reference·평가 기준·배포 권한을 바꾸지 않습니다.

접선: 미실행 제안 · 붉은 선: 승인 경계 | 작성자 제한, 공식 로드맵 아님

근거: AX JD · furiosa-opt 9b9cf0f · CPU/B 기록 2026-09-16

그림 6. 더 깊은 하드웨어 접근이 모든 AX 업무의 필수 종착점은 아닙니다. 업무에 필요한 근거와 담당자·도구·장치 접근 조건이 있을 때 해당 경로를 엽니다. 현재 완료와 후속 제안을 구분한 자체 설계입니다.

새 칩으로 확장할 때에도 이전 결과를 자동 승계하지 않습니다. 3세대에 공개된 compute/I/O die 분리·HBM4/4E·scale-up 통신은 새로 살필 데이터 이동과 실행 조건을 제시합니다. 실제 명세·SDK·장치가 제공되면 target별 계약을 추가하고, 기존 절차의 적용 범위를 다시 확인하겠습니다. 이는 공개 개발 계획을 바탕으로 한 조건부 확장입니다.[18]

6.2 Replay-Based Search Policy Evaluation

작은 절차의 재사용이 확인된 뒤에도 후보 탐색 비용이 크다면, 이미 실행한 분기 기록으로 탐색 순서를 비교할 수 있습니다.

DREAM은 coding agent와 evaluator를 고정한 채 어디에서 분기하고 무엇을 병렬 실행하며 언제 멈출지를 정책 코드로 다룹니다. 기록된 tree의 결과를 재생하므로 그 범위에서는 새 discovery 실행 없이 정책을 비교합니다. 기록 밖 분기에는 새 실행이 필요합니다.[19]

이 발상은 지금 별도 엔진을 도입할 이유보다 기록할 항목을 정하는 근거입니다. 부모 후보, 실제 시도, 관측, 선택·중단 이유와 비용이 있어야 나중에 다른 정책을 비교할 수 있습니다. 재생의 승자를 바로 팀 절차로 채택하지 않고 새 과제의 독립 확인을 거치겠습니다. 같은 이력의 재생 평가값 비감소는 새 업무의 개선 보장이 아니며, 정책 개발·재생·저장·검토 비용도 포함해 비교해야 합니다.

DGM의 후보 계보와 후속 과제 평가, *The Last AI Built by Humans*의 지속되는 변경과 개선 권한 구분도 이 경계를 설명하는 참고입니다. MD를 저장한 상태, 다음 작업에서 사용한 상태, 효과를 확인한 상태를 나눕니다. 실제 팀의 유지보수에서 유용한 작은 절차부터 남기고, 반복 사용의 근거가 쌓일 때 실행 정책으로 바꾸는 방향을 제안합니다.[20]

References and Evidence Scope

공개 자료의 구조와 개인 실행의 결과를 구분했습니다. 전문가 관찰, 팀 도입, 정적 compile/schedule과 NPU·서빙 실험은 후속 제안입니다. 보호된 실행 원본은 로컬에 보존하고 공개 저장소에는 재현 시스템과 필요한 계약만 둡니다. 목차로 돌아가기

1. **GEODE.** 코드 pin dcaa764, 반복 성공 종료 수정, 개발 규약. 실행·문맥·권한의 구현과 mock 회귀 근거입니다. 규약 존재를 준수율·생산성 측정으로 계산하지 않습니다.
2. **Eco².** Backend pin 4c3eebb, ACK 정책 수정. Consumer 전후 대조는 격리 재현이며 서비스 통합 재측정과 다릅니다.
3. **SIL·Crucible.** Seed Generation, Scaffold search, 기각 후 복원 수정, Petri 공식 소개. 일부 seed는 모의 응답을 사용하며 search 재평가는 옵션입니다. 설계·수정 근거와 자동 실행 이력을 구분합니다.
4. **Harbor 비교의 날짜와 모집단.** Harbor 0.22.0, 로컬 terminalbench21-sol-max-fullsuite-paired-20260827t190300z, analysis SHA 앞 12자리 c32619e98bb3, 2026-09-12 확인. amd64 검증기 두 과제를 대칭 제외한 뒤에도 native 측 6셀에 인프라 무효가 남았습니다. 공통 유효 429셀에서 GEODE 339·Codex 331 통과는 보조 관측이며 전체 평가값이나 인과적 우위가 아닙니다. 공개 평가 저장소는 안내 경로이며 이 로컬 분석의 공개 완료 증거와 다릅니다.
5. **Compiler AX Lab.** 고정 공개 결과, 예제·검사, B 검토·채택 기록, CI 구현 pin ce80c6f. SDK 9b9cf0fdc78df00cdc430eae725a5ad9084a735e, nightly 2026-05-01. A/B 단위는 고정 후보×구현 ID입니다. 검토는 OpenAI Codex / gpt-6-astra / ultra, 생성 요청은 high입니다. 공개 예제는 별도로 측정한 이전 reference이고 보호된 B 원본은 로컬에 보존합니다. Source-clean parser·합성 상태 복원·native smoke는 별도 모집단입니다.

A/B 최종 산출물 825개의 무결성을 재확인해 소스·바이너리·명령·결과·assertion 위치를 연결했습니다. 이는 신규 수치 재실행과 다릅니다. 이전 공개 테스트·parser 변경의 별도 통합 실행은 일반 테스트 720개와 doctest 55개를 통과했습니다. Doctest 중 44개가 compile_fail이며 ignored test 17개는 제외했습니다. 환경은 Ubuntu 24.04 amd64/Rosetta, 2 CPU·6 GiB, Cargo jobs=1입니다. 이 수치를 B의 통합 검증 결과로 이전하지 않습니다.
6. **TCP·RNGD 데이터 흐름.** Hanjoon Kim 외, TCP: A Tensor Contraction Processor for AI Workloads, ISCA 2024, §I-II·IV-V, Fig.2-3·8-9. Younggeun Choi 외, FuriosaAI RNGD: A Tensor Contraction Processor for Sustainable AI Computing, IEEE Micro 45(3), 2025, 저자본 1-6쪽. 당시 탐색 알고리즘과 현재 내부 pass는 구분합니다.
7. **Programming model과 공개 검사.** RENEGADE 2026 01:30:44, SDK 2026.3, 0.8.1 kernel validation, 공개 driver. 구조 compile-plain Cargo CPU 값·schedule·NPU 검사는 별도 근거입니다. 공개 Rust 경로를 내부 전체 구현과 동일시하지 않습니다.
8. **실행·산출물 책임.** Software Stack, FXB, Runtime, 장치 접근 조건, Furiosa-LLM serve. 호환성·실제 출력·서비스 SLO를 분리합니다.
9. **변환의 보존 조건.** Cornell CS4120 IR Lowering과 Arm TOSA 1.0.2 §1.10. 값·효과·평가 순서와 검사 비완전성의 원리를 사용하며 특정 TCP 변환의 증명으로 대체하지 않습니다.
10. **모델 적용 사례.** Solar on Daum, 2026-07-31; EXAONE 3.5 공동 배포, 2025-07-22; SDK 2026.2, ArtifactBuilder, Hybrid KV. 협업 사례와 EXAONE 4 후속 변경을 구분합니다. Bucket·KV 분리 실험은 본 보고서의 미실행 제안입니다.
11. **운영 계층.** 삼성SDS NPUaaS, 2026-07-20; Lablup-Furiosa RNGD meets Backend.AI, July 2026 v1.0. 자원 배정·세션·서빙 책임의 참고이며 내부 장애 빈도·인력 공수의 근거로 쓰지 않습니다.
12. **Compiler AX 역할.** 공식 채용 공고, 2026-09-16 확인. 실제 업무의 실험·도구 정착·playbook·온보딩과 PR cycle/review/triage/flakiness의 영향 측정을 제시합니다. 구체 내부 병목의 우선순위는 관측으로 확인할 항목입니다.
13. **생성·실험 설계.** co-scientist §3.3·4.1, AlphaEvolve §2·4, autoresearch program.md pin 228791f. 역할 분리·실행 평가·고정 비교를 적용합니다. AlphaChip 원문은 빠른 근사와 실제 설계 검증을 분리하는 참고이며 배치 RL을 이 실험에 구현한 것은 아닙니다.
14. **검사와 관측의 신뢰성.** LLVM Benchmarking, OSS-Fuzz target generation, SQLite testing. 환경·실제 도달·회귀 확인의 원리를 참고했습니다. 네 칸 판정표는 본 제안이며 회사의 현재 운영 규정이 아닙니다.
15. **선택적 데이터 조회.** AWS Bedrock AgentCore RLM, 2026-05-21; Redis HGETALL·HSCAN. 큰 묶음의 조회 비용을 참고합니다. HSCAN COUNT는 엄격한 바이트 상한이 아닙니다. Manifest·완전성·보존 정책은 자체 적용안이고 Redis 도입을 전제하지 않습니다.
16. **Dioxus 운영·문서 구조.** Jonathan Kelley, Building ambitious software, 2026-09-11, 보존 자동 전사 06:18-09:53·10:47-11:14·14:21-18:08. 발표자의 회고와 독립 실측은 구분합니다. AGENTS·architecture notes는 짧은 진입점과 작업별 읽기 경로의 참고입니다. Head/base 확인과 별도 release 승인은 본 설계입니다.

17. **정적 스케줄 진단.** furiosa-opt pin 9b9cf0f 의 Diagnosis-Tuning. 마지막 완료를 결정하는 구간의 의존성·자원·빈 구간을 구분하고 한 선택씩 비교합니다. 이번 CPU 파일럿의 완료 범위에 포함되지 않습니다.
18. **현재 칩과 후속 계획.** RNGD 사양, Broadcom 협력 발표, 2026-05-27; 회사 보도자료 재배포의 2028년 상반기 sampling 계획. 미래 칩의 구현·ABI·RNGD 호환성·탐색 공간 증가량은 공개 확인된 결과로 쓰지 않습니다.
19. **DREAM.** Tong Zheng 외, Dream-RSI: Recursive Self-Improvement through Evolving Worlds, 2026-09-14, §3-5; 공식 사이트, 저장소, 9월 16일 확인. 현재 정책을 후보에 포함한 같은 이력의 평균 재생 목적함수에서 비감소합니다. 새 업무·실제 지연·총비용 보장은 별도입니다. 사이트 시연은 설명용 수치이며 전체 실행·재현 코드는 공개 준비 상태입니다. 기록 tree와 조건부 경로의 시각 원리만 참고했습니다.
20. **후속 개선의 분류.** Zhang 외, Darwin Gödel Machine v3, §3-4·Appendix H 및 archive 선택. 후보 보존과 부모 대비 개선 채택은 다릅니다. The Last AI Built by Humans v2, §3.6-3.7·Fig.8은 지속되는 변경·개선 권한·외부 제약을 구분하는 참고입니다. 설명용 미래 곡선을 전망치로 사용하지 않았습니다.